

LiSA：再照明可能な Gaussian Splatting のためのライト空間アトラス

CVPR 匿名投稿

論文番号 *****




図 1. 光源視点からの再照明。点光源からガウシアンを一回ラスタライズすると、光がどの深度で吸収されるか (a) と、何に当たったかが、学習した光束特徴 (b、八チャネルのうち一つ) を通じて記録される。カメラ画素はこのアトラスを参照し、影にあるか (c) と、どれだけの光を局所的に反射するか (d) を決める。光輸送項 (e) は、モデルが主に半透明の花瓶とサイコロに割り当てる放射輝度を追加する。これは学習された配分であり、物理的な分解ではない。和 (f) はテストビュー (g) に対して 34.4 dB を達成し、近年の四つのベースラインの最良値 32.6 dB を上回る。成分 (d, e) は線形放射輝度上で加算され、黒背景で示されている。

要旨

点光源が物体の周囲を移動するとき、見え方の変化の多くは光がどこに当たるかによって生じる。再照明可能な Gaussian Splatting の既存手法はこれをプリミティブごとに推定するが、本研究では光源の画像平面上で考える。光源からガウシアンをラスタライズすると、アルファ合成重みは、各プリミティブがその光源画素の光束を受け止める割合を表す。LiSA は、この光束の沈着を、深度モーメントと学習した光束特徴からなるライト空間アトラスに記録する。学習時のガウシアンでも、レンダリング時の画素でも、任意の受光点がアトラスのピラミッドを参照することで、小さなネットワークで補正したフィルタ付きシャドウ判定と、沈着した特徴に対して線形な光輸送項を得られる。また、幾何形状が形成される間は、表示用に符号化した放射輝度ではなく線形放射輝度上で損失を計算する必要がある。細かい構造が複雑に入り組む二つのシーンをを用いた対照実験では、この変更によりホールドアウトしたビューの PSNR が 6-7 dB 向上した。三つの公開ベンチマークの 18 シーンで、LiSA は平均 PSNR 33.47 dB を

達成した。これは近年の四つのベースラインのうち最良の 31.59 dB を上回り、すべてのベンチマークで上位二位以内に入る唯一の手法であり、学習時間は約 20 分である。アブレーション実験は光輸送項の有効範囲も明らかにしている。半透明材質では特に重要である一方、ほとんどの他の材質では同規模の局所ネットワークが同等の結果を得る。

1. はじめに

物体を一度に一つの光源で撮影する one light at a time (OLAT) 方式と、新たな視点からの再照明は、写実的なデジタルアセットを作成するための最も古くからある方法の一つである [13]。近年では、各画像を一つの校正済み点光源で照らした数百から数千枚の画像から再照明可能な表現を再構成し [3, 62]、Gaussian Splatting [31] によってその結果を実時間でレンダリングできるようになった [5, 17, 33, 35, 66]。

点光源下では、画像が自然に見えるかどうかを左右する要因の多くは、材質を評価する前に決まる。すなわち、光がどこに当たり、どこに当たらない

いかである。現在のガウシアンを用いた手法は、これをプリミティブごとに決定する。GS³ [5] と SSD-GS [66] は、光源に向けてシーンをスプラットし、各ガウシアンに一つの可視性値を与える。RNG [17] は深度シャドウマップを一つのスカラー手掛かりに集約し、半透明性は局所的な入力からガウシアンごとのネットワークで予測される [15, 66]。そのため、床上の大きなガウシアンは一つの影の値しか持たず、移動する影の境界を表現するには、その都度高密度化によって形状を細分する必要がある。

本研究では、光源の画像平面上で考える。点光源からガウシアンをラスタライズすると、アルファ合成重みは、各光源画素の光束をそのレイ上にあるプリミティブに分配する。スプラッティングモデルの範囲内では、これらの重みは各ガウシアンが遮り受け取る光束の割合である。したがって、一回の追加ラスタライズにより、各プリミティブがどれだけの光をどの深度で吸収したかが記録される。本研究ではこれを光束の沈着 (deposit) と呼ぶ。順方向レンダリングでは、既知の幾何形状上に手設計の量を記録するシャドウマップ [16, 42, 56]、translucent shadow map [9]、reflective shadow map [10] において、数十年にわたり光源視点がこのように使われてきた。本研究ではこれを、幾何形状と記録する量とともに学習する逆レンダリングへ導入する。

提案手法 LiSA (Light-Space Atlas) は、光源ごとに沈着の一次・二次深度モーメントと少数の学習した光束特徴をスプラットし、フィルタリングしてピラミッドを構築する (図 1)。シェーディングを評価する任意の点、すなわち受光点 (receiver) は、光源視点に投影され、このピラミッドを参照する。幾何形状の最適化中はガウシアン中心を、その後は画素を受光点とする。深度モーメントからは variance shadow map [16] に倣ったフィルタ付きシャドウ判定を得て、残差ネットワークで補正する。光束特徴は沈着した特徴に対して線形な光輸送項に入力され、これは translucent shadow map の学習版に相当する。アトラスには画像ごとに一回の 512² ラスタライズが必要であり、入力光源に対する相対量で記述され、勾配はアトラスを通じてガウシアンまで伝播する。

表示用に符号化した放射輝度上の損失でこのモデルを学習すると、Lego のブルドーザーのバケットのような細く入り組んだ構造が塊状に崩れた (図 4)。そこで、放射量に基づいて最適化を段階化する。まず、ネットワークを用いない点光源モデルで幾何形状を当てはめ、その間に目標値を表示用放射輝度から線形放射輝度へ徐々に移行する。これは GS³ と SSD-GS が HDR データに対して行う処理に相当する [5, 66]。次に、ガウシアン受光点を用いて完全モデルを線形放射輝度上で学習する。最後

に、幾何形状を固定し、画素受光点で外観を微調整する。二つのシーンの対照実験では、損失を計算する領域だけを変えることで、ホールドアウトしたビューの PSNR が Lego で 23.0 から 30.2 dB、Drums で 24.1 から 30.1 dB に向上した。

三つの公開 OLAT ベンチマーク [5, 15, 62] の全 18 シーンにおいて、GS³、SSD-GS、OLAT Gaussians [33]、RNG を共通の評価手順で再学習し、同一の目標画像で評価したところ、LiSA は平均 PSNR、SSIM、LPIPS のすべてで最良の結果を達成した (PSNR は 33.47 dB、次点は 31.59 dB)。学習時間はシーンあたり約 20 分である。ベンチマーク別では、最良のベースラインに対して実撮影データで 2.0 dB (ビューごとの 2D 位置合わせ後は 0.7 dB)、GS³ シーンで 0.4 dB 上回る一方、SSS-GS では OLAT Gaussians を 0.1 dB 下回る。このため、すべてのベンチマークで上位二位以内に入る唯一の手法となる。アブレーション実験は光輸送項の限界も示す。半透明材質では特に重要であるが、ほとんどの他の材質では同規模の局所ネットワークが同等の結果を得る。本研究の貢献は以下のとおりである。

- ・ガウシアンスプラットの点光源可視性と光輸送をライト空間で定式化する。光源からの一回のラスタライズで沈着を記録し、受光点はそこからフィルタ付きの学習可能なシャドウ判定と、沈着した特徴に対して線形な光輸送項を導く。
- ・放射量に基づく段階的最適化により、細く入り組んだ幾何形状でもモデルを学習可能にする。対照実験を通じて、損失を計算する領域がそのような幾何形状の形成可否を決めることを示す。
- ・18 シーンの分析により、ライト空間の光輸送が有効な場合と局所ネットワークで十分な場合を明らかにする。また、現在の OLAT ベンチマークのテスト光源は学習光源からの角度差の中央値がわずかに 1.1° であり、光源の外挿をほとんど評価していないことを示す。

2. 関連研究

点光源下の撮影画像からの再照明。 Neural reflectance field は OLAT 照明から再照明可能なボリュームを復元する [3, 4]。NRHints [62] は、レイトレーシングで得た影とハイライトの手掛かりを条件として放射輝度場を推定する。環境光下の逆レンダリングでは、シーンを幾何形状と BRDF に分解する [7, 20, 21, 27, 29, 34, 50, 65]。点光源に対して、GS³ [5] は空間・角度ガウシアン、スプラットによる影、残差ネットワークを組み合わせる。RNG [17] は、ネットワークで補正した深度シャドウマップの手掛かりを用いてニューラルガウシアン特徴をシェーディングし、学習中に順方向から遅延シェーディ

141 ングへ切り替える。OLAT Gaussians [33] はニュー
142 ラル表面再構成 [53] による代理メッシュをガイドと
143 して用い、BiGS [35] は双方向球面調和関数を用い
144 る。SSS-GS [15] はニューラル表面下散乱の残差を追
145 加し、SSD-GS [66] は散乱、影、反射を分離する。
146 RadiosityGS [26] と確率的レイトレーシング [57]
147 は、ガウシアン上で光輸送を明示的に解く。ニュー
148 ラル透過率場と放射輝度輸送場は、放射輝度場の
149 可視性と光輸送を学習する [37, 48]。PRTGS [22] は
150 遠方光源下のガウシアン放射輝度輸送を事前計算
151 し、再照明可能なアバターは人体モデル上で影と光
152 輸送を学習する [6, 46, 54]。これらはいずれもプリ
153 ミティブごと、またはレイごとに可視性や散乱を評
154 価するが、LiSA はその両方を光源の画像平面へ移
155 す。

156 **ガウシアンの可視性。** ガウシアンごとの可視性
157 は、光源へのスプラッティング [5, 66]、ガウシアン
158 を通るレイの追跡 [20, 21, 40, 57]、あるいは深度シ
159 ャドウマップ [17] から求められる。Deep Gaussian
160 shadow map [39] は固定されたガウシアンの透過率
161 を表に記録する。本研究のアトラスはフィルタリン
162 グ可能で、任意の受光点で評価され、表現対象の幾
163 何形状とともに学習される。

164 **ライト空間でのレンダリング。** シャドウマッ
165 プ [56] とそのフィルタリング版 [1, 2, 16, 18,
166 42, 45]、半透明遮蔽物のためのシャドウマッ
167 プ [24, 32, 36, 43, 47, 61]、拡散モデル [14, 25] に基
168 づく translucent shadow map [9, 28]、reflective
169 shadow map [10, 11]、および多重スケールの光表
170 現 [8, 30] は、光源ごとの量を保存し、シェーディ
171ング時に集約する。また、事前計算放射輝度輸送は、
172 出射光を入射光の線形関数として表現する [49]。本
173 研究のシャドウ判定は、不透明度で重み付けした沈
174 着に対する二つのモーメントを用いた判定であり、
175 variance shadow map や opacity shadow map に
176 近い。光輸送項は、送光点の位置を明示的に用い
177 ず、事前にフィルタリングした各階層上で計算す
178 る translucent shadow map に類似する。学習を
179 用いた関連手法には、既知の幾何形状に対してシ
180 ャドウマップのバッファをフィルタリングするもの
181 の [12] や、ラスタライズ済みバッファを復号するもの
182 の [19, 41, 52, 58, 64] がある。LiSA は幾何形状を再
183 構成しながら、保存する量とカーネルを学習する。

184 **損失を計算する領域。** RawNeRF [38] は、トーン
185 マッピング後の誤差を近似するように線形領域の損
186 失を再重み付けし、GS³ [5] は HDR 目標画像のガン
187 マを線形放射輝度へ向けて徐々に変化させる。本研

究のモデルでは、表示領域の損失が細い幾何形状の
形成を妨げた (第 4 節)。

3. ライト空間アトラス

校正済みカメラで撮影した画像 $\{Y_m\}$ から物体を再
構成する。各画像は、位置 $\mathbf{p}_m$ 、RGB 強度 $\mathbf{I}_m$ の点光
源下で撮影されている (図 2)。

3.1. 準備

シーンは、平均 μ_i 、共分散 Σ_i 、不透明度 α_i を持つ
3D ガウシアンの集合である [31]。各ガウシアンは、
ベースカラー $\mathbf{b}_i \in \mathbb{R}^3$ と潜在材質コード $\mathbf{f}_i \in \mathbb{R}^{32}$ を
持ち、その先頭三チャンネルが学習する単位法線 $\mathbf{n}_i$ を
定める。スプラッティングは、ガウシアンごとの属
性 $\mathbf{c}_i$ を手前から奥へ合成する。

$$\bar{\mathbf{c}}(u) = \sum_i w_i(u) \mathbf{c}_i, \quad w_i(u) = \alpha_i(u) \prod_{j < i} (1 - \alpha_j(u)), \quad (1)$$

ここで、 $\alpha_i(u)$ は画素 u におけるガウシアン i の不透
明度である。点 $\mathbf{x}$ において、単位光源方向、単位視
線方向、単位ハーフベクトルをそれぞれ $\mathbf{l}, \mathbf{v}, \mathbf{h}$ と書
き、法線入射時の放射照度を $\bar{E}(\mathbf{x}) = \mathbf{I} / \|\mathbf{p} - \mathbf{x}\|^2$ とす
る。

3.2. 光源からのスプラッティングによる沈着の記録

光源位置にシーン中心へ向けた透視投影カメラを置
き、99.9% のガウシアンのスプラット範囲を覆う画
角を設定する。その画素 u は立体角 $d\omega_u$ を張り、
光束 $\mathbf{I} d\omega_u$ を受け取る。スプラッティングでは、各
ガウシアンがレイに沿って進む残りの光のうち $\alpha_i(u)$
の割合を吸収するとみなす。したがって、そのガウ
シアンが遮り受け取る光束は

$$P_i(u) = \mathbf{I} d\omega_u w_i(u), \quad (2)$$

となり、重みは式 (1) と同じである。この関係は
ラスタライズされたスプラッティングモデルの範
囲内で成立する。そのモデルでは、タイルごとの中
心深度によるソート、ローパスフィルタ、不透明度
のクランプによって体積透過率を近似する [23, 44,
51, 60]。式 (2) には法線も距離も現れない。距離
 r 、入射角 θ にある微小面積 dA が受け取る光束は
 $\mathbf{I} \cos \theta dA / r^2 = \mathbf{I} d\omega$ であり、投影による面積の縮小
と距離減衰は、表面が覆う光源画素の数に織り込ま
れるためである。

アトラス。 各ガウシアンは $\mathbf{c}_i = [\phi_i, z_i, z_i^2, 1]$ を
出力する。ここで、 z_i は光源の光軸に沿ったガウ
シアン中心の深度をシーン中心に対する相対量と




図 2. 手法の概要。各光源について、ガウシアンを光源から一回ラスタライズする。各ガウシアンは、遮り受け取る光の割合に等しい合成重みで、学習した光束特徴 ϕ_i と深度モーメントを沈着させる (式 (3))。受光点は光源視点に投影され、ピラミッドから多重スケールの統計量と光束を集約する。モーメントによるシャドウ判定への残差、集約した光束特徴に線形に作用する光輸送カーネル、および局所材質によってシェーディングされる。サムネイルは Hotdog モデルのテストビューでの実際のバッファである。下部は第 4 節のスケジュールを示す。

して表し、シーン半径で正規化した値である。また、 $\phi_i = \text{softplus}(\text{MLP}_\phi(\mathbf{f}_i, \mathbf{b}_i, \mathbf{n}_i \cdot \mathbf{l}_i)) \in \mathbb{R}_+^C$ は $C = 8$ 個の学習した光束特徴である。512² での一回のラスタライズから、次のアトラスを得る。

$$\mathbf{A}(u) = \sum_i w_i(u) \mathbf{c}_i = [\Phi(u), M_1(u), M_2(u), M_0(u)], \quad (3)$$

これは、画素への入射光束の単位量あたりの沈着を表す。 M_0 はその光束のうちシーンが吸収する割合、 M_1/M_0 と M_2/M_0 は吸収が生じる深度の一次・二次モーメントであり、 Φ は光が何に当たったかを記述する。絶対的な沈着量 $\mathbf{I} d\omega_u \mathbf{A}(u)$ には、光軸からの角度に対して $d\omega_u \propto \cos^3$ となる係数も含まれる。この係数の変動は、本研究のデータの典型的なアトラス全域では 30% 未満であるが、最も広いアトラスの隅では最大 2.1 $\times$ に達する。以下の影の統計量はこの係数に依存しない比であり、光輸送項ではこの係数を無視する。二項フィルタによるぼかしと 2 $\times$ の間引きを繰り返して、 $K = 7$ 層のピラミッド $\mathbf{A}_0, \dots, \mathbf{A}_{K-1}$ を構築する。各チャネルは重み w_i に対して線形であるため、各階層でも沈着のモーメントと特徴の和が保持される。集約範囲は一つのテクセルから物体の約三分の一まで広がり、この性質がこの種のシャドウマップのフィルタリングを可能にする [16, 42]。

3.3. アトラスからのシェーディング

受光点 $\mathbf{x}$ を光源視点の位置 $u(\mathbf{x})$ に、正規化深度 $z(\mathbf{x})$ で投影し、各階層を双線形補間でサンプリングする。階層 k では、平均沈着深度 $\bar{z}_k = M_{1,k}/M_{0,k}$ 、

テクセルサイズ τ_k を含む広がり $\eta_k = (M_{2,k}/M_{0,k} - \bar{z}_k^2 + \tau_k^2)^{1/2}$ 、沈着の背後にある受光点の深度差 $\delta_k = z - \bar{z}_k$ 、および $t_k = \delta_k/\eta_k$ を計算する。集約範囲内の沈着深度が正規分布に従うならば、受光点より手前で吸収される光の割合は、標準正規分布の累積分布関数 G を用いて $M_{0,k} G(t_k)$ と表される。これから次のモーメント判定を得る。

$$V_k = 1 - M_{0,k} G(t_k - \beta), \quad (4)$$

ここで、局所的な広がり単位とするバイアス $\beta = 3$ は自己遮蔽を防ぐ。全階層の記述子 $\mathbf{q}_k = [M_{0,k}, t_k, \delta_k, \log \eta_k, V_k]$ をまとめて $\mathbf{Q}(\mathbf{x}) \in \mathbb{R}^{5K}$ とする。遮蔽物と受光点が同じ集約範囲に含まれる場合、この判定は弱い事前知識にとどまる。例えば、不透明な受光点の前に半透明の遮蔽物がある場合には $t_0 = 1$ となり、式 (4) は正しい 0.5 ではなく 0.98 を返す。一方、variance shadow map のチェビシェフ境界はこの場合に正しい値を返す [16]。また、各ガウシアンは中心の深度を沈着させるため、大きなガウシアンに斜めから光が当たっていても、単一深度として表現される。

可視性。 ゼロに初期化した残差ネットワーク $\mathcal{G}$ によって、最も細かい階層の判定を補正する。

$$V(\mathbf{x}) = \sigma(\text{logit } V_0(\mathbf{x}) + \mathcal{G}(\mathbf{Q}, \mathbf{f}, \mathbf{n} \cdot \mathbf{l})), \quad (5)$$

したがって、学習は古典的なフィルタ付きシャドウマップから始まり、 $\mathcal{G}$ は多重スケールの統計量から、上述の例、毛の部分的な透過、有限の大きさを

283 持つ実光源による柔らかな影の境界を補正すること
284 を学習する。

285 **光輸送。** 式 (2) より、半透明物体に入り、 $\mathbf{x}$ から
286 出る光の寄与は $\mathbf{I} / \sum_i R(\mathbf{x}, \mu_i) w_i(\omega) d\omega$ となる。これ
287 は、受光点に依存するカーネル R を、光源の立体角
288 全体にわたって沈着に対して積分したものである。
289 Translucent shadow map は、保存した放射照度と
290 固定の拡散カーネルを用いて、この種の積分を計算
291 する [9, 14, 28]。本研究では、ピラミッドの各階層
292 を幅の異なるカーネルとして用い、沈着する特徴と
293 カーネルの両方を学習する。

$$294 L_{\text{tr}}(\mathbf{x}) = \sum_k \mathbf{W}_k \Phi_k(\mathbf{x}), \quad (6)$$

$$295 \{\mathbf{W}_k\}_k = \text{softplus}(\mathcal{K}(\mathbf{Q}, \mathbf{f}, \mathbf{n} \cdot \mathbf{l}, \mathbf{n} \cdot \mathbf{v})), \quad \mathbf{W}_k \in \mathbb{R}_+^{3 \times C}.$$

296 カーネルは受光点と幾何統計量 $\mathbf{Q}$ のみに依存するた
297 め、幾何形状と光源を固定すれば、 L_{tr} は沈着した特
298 徴に対して線形である。ただし、受光点自身の沈着
299 も集約範囲に含まれるため、 L_{tr} が直接反射の一部を
300 担うことも妨げられず、各項への配分は学習によっ
301 て決まる。

302 **局所材質と放射輝度。** 局所反射率 $\rho(\mathbf{x})$ は、潜在コ
303 ードを用いたニューラル BRDF である。 $\mathbf{f}, \mathbf{n}, \mathbf{l}, \mathbf{v}, \mathbf{h}$
304 および反射視線方向 $\mathbf{r}$ のフーリエ符号化、それらの
305 余弦、ハイライトの手掛かり $e^{\kappa(\mathbf{n} \cdot \mathbf{h} - 1)}$ [62] を入力す
306 る MLP に、平滑化した余弦 $\psi(\mathbf{n} \cdot \mathbf{l}) = \text{softplus}(20\mathbf{n} \cdot \mathbf{l})/20$ を掛けたものである。位置情報は、光源に依
307 存する八つの応答を混合する、光源に依存しない
308 八つの係数を通してのみ入力される。これにより、
309 投影される影が材質へ焼き込まれる程度を制限す
310 るが、自由なガウシアンごとのコードにより一部
311 の焼き込みはなお可能である。また、固定の鋭さ
312 $\kappa \in \{8, \dots, 2048\}$ と光源に依存しない重みを持つ等
313 方的ローブ $s(\mathbf{x})$ が鋭いハイライトを表現する。出射
314 放射輝度は次式で与えられる。
315

$$316 L(\mathbf{x}) = \bar{E}(\mathbf{x}) [V(\mathbf{x}) \rho(\mathbf{x}) + V_0(\mathbf{x}) s(\mathbf{x}) + L_{\text{tr}}(\mathbf{x})]. \quad (7)$$

317 ローブには幾何に基づく判定 V_0 を用いるため、学習
318 した V がまだ誤っている場所でも、ハイライトへの
319 勾配経路が維持される。 $\bar{E}(\mathbf{x})$ を括り出すことで、ネ
320 ットワークは反射率に類する量を予測できる。 L_{tr} に
321 対しては、これにより入射点での距離減衰が受光点
322 での距離減衰に置き換わり、背面照明による透過で
323 は光源からの距離の比の二乗 $(r_{\text{out}}/r_{\text{in}})^2$ に相当する
324 誤差が生じる。カーネルがこの誤差を吸収できるの
325 は平均的な意味でのみであるが、一つの撮影デー
326 内で光源距離の変化が小さい場合には十分である。
327 距離は合成シーンでは一定であり、実撮影シーンで

は最大 $1.8 \times$ の範囲に収まる (補足資料)。 $\mathcal{G}$ と $\mathcal{K}$
のすべての入力は光源に対する相対量であり、演算
子は光源位置を添字として持つのではなく、光源座
標系で定義される。この性質が外挿に有効かどうか
は、実験 E1 の検討対象である (Sec. 5.3)。

3.4. 受光点：ガウシアンまたは画素

ガウシアン受光点では、各ガウシアン中心 μ_i をシェ
ーディングしてから、式 (1) により色を合成する。画
素受光点では、まず $\mathbf{b}, \mathbf{f}$ と期待深度を合成し、各画
素を世界座標の点へ逆投影して、一度だけシェー
ディングする。ガウシアン受光点は、高密度化が依存
する通常のラスタライズ勾配を幾何形状に与え、重
なった表面間で材質が混ざること防ぐが、第 1 節
で述べたプリミティブごとの影の制約を引き継ぐ。
画素受光点は各画素自身の表面点でシャドウ判定を
評価するため、影の境界が大きなガウシアンの内部
を横切ることができる。RNG における順方向から遅
延シェーディングへの切り替え [17] と同様に、LiSA
は同一のアトラスを使いながら、幾何形状の最適化
中はガウシアン受光点を、形状を固定した後は画素
受光点を用いる (第 4 節)。

4. 放射量に基づく段階的最適化

4.1. 損失をどこで計算するか

再照明の測光損失は、LDR 撮影データの本来の形式
である、表示用に符号化された画像上で計算される
ことが多い。本研究では、HDR データの表示に純
粋なべき乗則 $\Gamma(L) = L^{1/\gamma}$ 、 $\gamma = 2.2$ を用い、LDR デ
ータの線形化にはその逆変換を用いる。このとき、
予測放射輝度 $\hat{L}$ に対する ℓ_1 損失の勾配の大きさは

$$\Gamma'(\hat{L}) = \frac{1}{\gamma} \hat{L}^{1/\gamma-1}, \quad (8)$$

となり、残差の大きさに依存しない。したがって、
白の一パーセントの値を予測した画素には、残差が
ごく小さくても、白を予測した画素の十二倍の勾配
が与えられる。式 (7) の予測は学習する複数の因子
の積であるため、学習初期に画素が暗いのは、可視
性、法線、材質のいずれかがまだ誤っていることだ
けが原因の場合も多い。本研究では、そのような画
素が幾何形状に到達する勾配を支配し、最適化器が
細い構造を平滑化することでそれを解消する、とい
う仮説を立てる。Sec. 5.4 の対照実験は、本研究の
モデルにおいて、損失を計算する領域が細い幾何形
状の形成可否を決めることを示す。ただし、その機
序を切り分けたものではなく、 Γ 内へのオフセット
の導入や損失の再重み付け [38] といった対策も未検
証である。

373 4.2. 三つの段階

374 32 枚の学習用シルエットから視体積交差法で推定し
375 た形状の内部に、20k 個のガウシアンを一様に配置
376 する。ある点がシルエットの少なくとも 90% の内側
377 に投影される場合にその点を採用し、法線はシーン
378 中心から外向きに初期化する。

379 I. 幾何形状のウォームアップ (8k 回の反復)。
380 ネットワークを用いない点光源モデルで、各ガウ
381 シアンの色を $\text{softplus}(\mathbf{b}_i) \bar{E}(\mu_i) \psi(\mathbf{n}_i \cdot \mathbf{l}_i)$ とし、幾何
382 形状、ベースカラー、法線だけを最適化する。レン
383 ダラの出力は線形のまま、目標値を変化させる。ウ
384 ォームアップの最初の三分の二では表示用に符号化
385 した画像 $\Gamma(Y)$ を目標とし、その後、ベキ指数を $1/\gamma$
386 から 1 へ線形に変化させる。これにより、幾何形状
387 はダイナミックレンジを圧縮した目標値に対して形
388 成され、連続的に線形放射輝度へ移行する。GS³ と
389 SSD-GS は HDR 学習画像に類似の漸進的移行を適
390 用する [5, 66]。本研究ではこれをすべてのデータ群
391 に適用し、その後の同時学習も線形放射輝度上で行
392 う。

393 II. 同時学習 (22k 回の反復)。式 (7) の完全モデル
394 を、ガウシアン受光点と線形放射輝度上の損失を用
395 いて学習する。高密度化と枝刈りは反復 25k ま
396 で 3DGS [31] に従って行い、ガウシアン数の上限を
397 400k とする。

398 III. 外観の微調整 (8k 回の反復)。幾何形状とカ
399 メラ校正を固定し、受光点を画素に切り替え、損失
400 を画像の評価に用いる表示領域へ戻す。幾何形状を
401 固定した場合、本研究の実験では、暗い画素に対す
402 る重みの増加が両種の受光点で三つの評価指標すべ
403 てを改善する (Sec. 5.4)。

404 すべての段階で、現在の目標領域上で計算した
405 $0.8l_1 + 0.2(1 - \text{SSIM})$ を最小化する。さらに、ベン
406 チマークが提供する前景マスク α を用いたレンダリ
407 ング不透明度の損失 $0.5 \|\hat{\alpha} - \alpha\|_1$ と、コード $\mathbf{f}$ に対す
408 る弱い l_2 正則化を加える。

409 4.3. 実装の詳細

410 LiSA は PyTorch と gsplat [59] を使用し、512² テク
411 セル、 $K = 7$ 層、 $C = 8$ 光束チャネルのアトラス
412 と、幅 128 (可視性は 64) の MLP を用いる。学習
413 が $L_{\text{tr}} \approx 0$ および $V = V_0$ から始まるように初期
414 化し、Adam を使用する (ネットワークの学習率は
415 10^{-3} から約四分の一まで減衰、ガウシアンは 3DGS
416 と同じ設定)。実撮影データでは、校正済みの中心
417 を固定して各学習カメラの回転も微調整する。各ス

テップ後に、その微調整が吸収しうる全体の並進成
分を除去し、再構成を校正済み座標系に保つ。テスト
カメラと光源は一切調整しない。各ベンチマーク
のデータ規約だけを変え、全 18 シーンに一つの設定
を共通で用いる。一回の完全な学習は NVIDIA RTX
6000 Ada 一枚で 17 から 28 分 (平均 21 分) を要す
る。

5. 実験

5.1. 実験設定

データ。三つの公開 OLAT ベンチマークのすべての
シーンを使用する。NRHints [62] の七つの実撮影
シーン (各シーンに学習画像 522–1500 枚、テスト
画像 66–200 枚)、GS³ [5] の六つの HDR 合成シー
ン (2000/400)、SSS-GS [15] の五つの表面下散乱
シーン (500/500) である。各ベンチマークの規約
(画像は 512 px、SSS-GS は 256 px。HDR は白背景
で $\gamma = 2.2$ により表示) を維持し、すべての公式学習
画像と全 5,691 枚のテスト画像を用いる。

ベースライン。点光源下の撮影画像からシーンご
とに学習し、コードが公開されている近年の四つ
のガウシアン手法、GS³ [5]、SSD-GS [66]、OLAT
Gaussians (OLAT-GS) [33]、RNG [17] と比較す
る。公開コードと既定のスケジュールで再学習す
る (60k–100k 回の反復。本手法は 38k)。すべての
手法が前景マスクを目標画像の合成に用いる。
OLAT-GS は表面再構成段階にも、LiSA は不透明度
損失にもマスクを用いる。GS³、SSD-GS、OLAT-
GS は実撮影シーンで学習時の姿勢を微調整し、い
ずれの手法もテストカメラや光源を当てはめない。
RNG と OLAT-GS は複数のシーン (例えば Drums、
Lego) で 21 dB を下回る。これは、これらのシーン
が手法の前提 (黒背景の LDR データ、代理表面) に
適合しない可能性があるためであり、得られた結果
をそのまま報告する。[E5, E6] SSS-GS [15] の安定し
た再現が得られた時点で比較に追加する (本研究の
実行では五つのうち三つのシーンで発散した)。ま
た、各ベースラインについて論文掲載の設定を一つ
再現する。

評価指標と手順。画像全体の PSNR、SSIM [55]、
VGG-LPIPS [63] を、まず各シーンのテストビュー
間で、次にシーン間で平均する。シーンごとの差は
Wilcoxon の符号付き順位検定で検証する。すべての
予測を共通の 8 ビット目標画像群で評価する (ベ
ースラインの平均値の変化は最大 0.005 dB)。前景
マスク内の PSNR でも各ベンチマーク内の順位は変
わらない (補足資料)。主結果は各手法・各シーン

表 1. 三つの OLAT ベンチマークの全 18 シーンでの比較。テスト画像は 5,691 枚、目標画像は共通とし、元のテスト校正を使用してテスト時の当てはめは行わない。最良値は太字、次点は下線で示す。反復数は RNG 30k+70k、OLAT-GS 30k+30k、GS³ 100k、SSD-GS 100k (SSS は 60k)、LiSA 38k。

手法	NRHints、実撮影 (7)			GS ³ 、合成 (6)			SSS-GS、合成 (5)			全シーン (18)		
	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
RNG [17]	20.94	.828	.203	22.14	.895	.132	37.10	.983	.028	25.83	.893	.131
OLAT-GS [33]	27.26	.886	.114	27.11	.940	.079	40.74	.990	.016	30.95	.933	.075
GS ³ [5]	<u>27.28</u>	.884	.116	<u>31.97</u>	<u>.967</u>	<u>.049</u>	36.81	.983	.028	31.49	<u>.939</u>	.069
SSD-GS [66]	27.20	.882	.117	31.53	.965	.050	37.79	<u>.986</u>	<u>.023</u>	<u>31.59</u>	<u>.939</u>	<u>.068</u>
LiSA (本手法)	29.28	.909	.100	32.40	.970	.038	<u>40.63</u>	.990	.016	33.47	.952	.056

で一回の実行、アブレーション実験は三つの乱数シードを用いる。開発中には LiSA の旧版もこれらのベンチマークで評価した（補足資料）。最終設定は学習集合から評価用に取り分けたビューで選択し、全シーンで共通とする。

5.2. 最先端手法との比較

LiSA は 18 シーンの平均 PSNR、SSIM、LPIPS で最良の結果を得て（表 1）、SSD-GS を 1.89dB 上回る。シーンごとの比較では、すべてのベースラインに対する優位性が有意である（ $p \leq 0.016$ ）。ベンチマークをまたいで一貫して優れるベースラインはない。OLAT-GS は SSS-GS で最良であるが、GS³ シーンでは LiSA を 5.3dB 下回る。GS³ は自身のシーンでは二位であるが、SSS-GS では最下位となる。LiSA はすべてのベンチマークで上位二位以内に入る唯一の手法であり、三つすべてで最良の LPIPS を得る。ただし、優位性は一部のシーンに集中している。三つの実撮影シーンが全体の差の 46% を占め、六つの GS³ シーンの PSNR では LiSA と GS³ がそれぞれ三つで最良となる（LPIPS では LiSA が五つで最良）。校正が正確な 11 の合成シーンでは、LiSA は SSD-GS を 1.77dB 上回る（ $p = 0.014$ ）が、OLAT-GS に対する差は有意ではない（ $p = 0.12$ ）。

最大の改善は、移動する投影される影や半透明物体を通過する光が支配的なシーンで得られ、最良のベースラインに対して Hotdog で 1.90dB、Translucent で 1.91dB 向上する。図 3 では、花瓶の取っ手やホットドッグの影が、床や皿を表す大きなガウシアン上に投影される。プリミティブごとの可視性は影を断片化するが、アトラスを参照する画素受光点はその輪郭を再現する。LiSA は Drums (−1.09dB) と AnisoMetal (−0.85dB) では劣る。これらの細い、あるいは異方的なハイライトは、本手法の等方的ロープでは捉えられない。

実撮影シーンでは LiSA が平均 2.0dB 上回るが、その改善はすべて Cat、Fish、Pixiu による。他の四

つでは GS³ を 0.3dB 下回る。ここでの固定校正下の評価値は、外観だけでなく位置合わせにも依存する。公式姿勢には小さな誤差があり、再構成を固定する基準を設けずに学習姿勢を微調整すると、再構成がテストカメラに対して移動しうる。本手法のゲージ制約付き微調整 (Sec. 4.3) は、その仕組みによりこれを防ぐ。各テストレンダリングを最適な 2D 並進で位置合わせすると（補足資料）、その影響が分かる。ベースラインは 4.0–4.6 px の補正を要するのに対し、LiSA は 1.7 px であり、LiSA の優位性は 0.7dB に縮小する。Cat と Pixiu では大きな差が残るが、Fish では差が消える。**[未実施] E2: 姿勢微調整を除いた LiSA と、全手法に対する回転のみのテスト姿勢位置合わせ。**

5.3. アトラスの寄与

表 2 では、不透明、金属、毛、半透明、表面下散乱の材質を含む五つのシーン群でアトラスをアブレーションする。本手法が特に劣るシーンのうち三つを含み、完全モデルのシード間標準偏差は 0.11dB である。最も細かいアトラス階層のみを使用すると 0.44dB、学習した可視性を式 (4) のモーメント判定に置き換えると 0.24dB 低下する。ただし、これらの単一シードの差は両者の重要性を示唆するにとどまる。また、このシーン群では同一の受光点におけるアトラス可視性と、プリミティブごとの可視性または通常のシャドウマップをまだ比較しておらず、この比較は E3 で行う。

光輸送項の除去は、三つのシードすべてで PSNR を 1.37dB 低下させ、LPIPS を 0.047 から 0.055 へ悪化させる。この低下は材質に依存する（表 3）。Drums と FurScene では無視できる程度、AnisoMetal では 1.42dB、Translucent と Soap ではそれぞれ 2.29、2.99dB である。モデルは最初の三つのシーンでは線形放射輝度の 6–7% を光輸送項に配分するが、Translucent では 17%、Soap では 58% を配分する。全 18 シーンでは、不透明な合成物体で




図 3. 定性的比較。テストビューの枠内を切り出して示す（PSNR はビュー全体）。各画像は、そのシーンで最良のベースラインに対する LiSA のビューごとの優位性が中央値となるビューである。上から、投影される影が支配的な二つの GS³ シーン、各手法の差が小さい実撮影シーン、本手法が最も劣る合成シーンを示す。SSD-GS と GS³ のプリミティブごとの影は、花瓶の取っ手とホットドッグの移動する影を断片化するが、アトラスを参照する画素受光点はこれらを再現する。一方、LiSA は Drums のシンバルの細い光の筋を捉えられない。Fish を含む他のシーンは補足資料に示す。

6–9%、表面下散乱物体で 20–58% となる。これは学習された配分であり、物理的な分解ではない。

アトラスの効果と追加の放射輝度経路の効果に分けるため、アトラスによる影を維持しつつ、アトラスの光輸送を同容量の MLP に置き換える。この MLP は受光点のコード、位置、光源方向、視線方向を参照するが、アトラスは参照しない。この局所残差は平均で完全モデルと同等である (31.54 対 31.51 dB)。したがって、これらの材質の大半では、光輸送項の主な役割は影の影響を受けない非負の放射輝度経路を提供することであり、局所ネットワークでも同様に実現できる。アトラスが上回るのは、光が可視表面に到達する前に物体を通過する様子が明確に見える Translucent のみである ($+0.41 \pm 0.26$ dB)。三つのシードすべてで正の差だが、有意ではない。一方、局所残差は Soap (-0.29 ± 0.11 dB) と、わずかに Drums で上回る。AnisoMetal では完全モデルのシード間変動も大きい

(26.4–27.9 dB)。したがって、本研究の全体的な優位性を光輸送項に帰することはせず、ライト空間の可視性と最適化スケジュールが主因であるという仮説を立てる。これは E3 と E4 で検証する。光源に対する相対量を用いる設計は、光源の外挿で最も重要になると考えられるが、既存ベンチマークはそれを検証していない。テスト光源と最近傍の学習光源との角度差の中央値は 1.1° にすぎない。**[未実施] E1 (表 4)：アブレーション用シーン群で三つのシードを用いる。「アトラスは局所残差より劣化が小さい」という主張を前提とせず、検証する。**

5.4. 最適化の寄与

損失領域。 最初の実行で失敗した Lego と Drums において、16k 回の反復からなる二つの実行で初期化、ウォームアップ、スケジュール、乱数状態を共有し、損失だけを変える。対照条件は全期間にわたり表示用に符号化した放射輝度を用い、本手法

表 2. アトラスのアブレーション。五つのシーン（Drums、AnisoMetal、Translucent、FurScene、Soap）のシーン平均を示す。三つのシードを用いた行はシード間の平均と PSNR の標準偏差を報告し、単一シードの行はシード 0 の完全モデル（31.53 dB）と比較する。[†]容量を揃えた MLP（49.1k 対 49.6k パラメータ）は受光点のコード、位置、光源・視線方向を参照するが、アトラスは参照しない。影には引き続きアトラスを用いる。

条件	シード数	PSNR [↑]	SSIM [↑]	LPIPS [↓]
完全モデル	3	31.51 $\pm$ 0.11	.954	.047
光輸送項なし	3	30.15 $\pm$ 0.11	.948	.055
光輸送 $\rightarrow$ 局所残差 [†]	3	31.54 $\pm$ 0.03	.954	.047
単一階層（ $K=1$ ）	1	31.09	.952	.049
モーメント判定のみ （ $g \equiv 0$ ）	1	31.29	.952	.048
各ガウシアン可視性 [‡]	3	未定	未定	未定
ハードシャドウマップ [‡]	3	未定	未定	未定

[†][未実施] E3（同じ受光点を使用し、光輸送にはアトラスを維持）。単一シードの行も三つのシードで実行する。

表 3. 光輸送項が重要となるシーン。完全モデルと、光輸送項を除いたモデルおよび同容量の局所残差モデルとのシーン別 PSNR 差（三つのシードの対応する差の平均 $\pm$ 標準偏差）と、完全モデルが光輸送項へ配分する線形放射輝度の割合（8 テストビューの平均）。

シーン	光輸送なし との差	局所残差 との差	光輸送の割合
Drums	+0.10 $\pm$ 0.02	-0.09 $\pm$ 0.02	6%
FurScene	+0.02 $\pm$ 0.03	+0.02 $\pm$ 0.02	7%
AnisoMetal	+1.42 $\pm$ 0.69	-0.18 $\pm$ 0.75	7%
Translucent	+2.29 $\pm$ 0.23	+0.41 $\pm$ 0.26	17%
Soap	+2.99 $\pm$ 0.30	-0.29 $\pm$ 0.11	58%

表 4. 学習から除外した光源方向（[未実施] E1）。五つのアブレーション用シーンにおける、公式テストビューと、光源方向が評価用に取り分けられた 30° 角度区間に入る学習集合内のビューの平均 PSNR。各手法をそれらのビューを除いて再学習する。[†]三つのシードを使用。

手法	公式テスト	除外した光源	低下幅
GS ³	31.25	未定	未定
SSD-GS	31.01	未定	未定
OLAT-GS	28.67	未定	未定
LiSA、局所残差 [†]	31.54	未定	未定
LiSA [†]	31.51	未定	未定

は段階 I と II に従う。学習集合から評価用に取り分けた 200 ビューで、表示領域の損失による幾何形状は崩れる（図 4）。一方、放射量に基づくスケジュールは PSNR を Lego で 23.02 から 30.25 dB、Drums で 24.10 から 30.10 dB に向上させる（LPIPS




図 4. 損失領域と幾何形状。二つの実行で初期化、スケジュール、乱数状態、その他すべての設定を共有し、損失を表示用に符号化した放射輝度上で計算するか、目標値を徐々に移行するウォームアップの後に線形放射輝度上で計算するかだけを変える。16k 回の反復を行い、学習集合から評価用に取り分けた 200 ビューの PSNR を示す。両シーンですべての 200 ビューが改善する。

は 0.122 $\rightarrow$ 0.057、0.060 $\rightarrow$ 0.034）。すべてのビューで改善し、改善幅の中央値はそれぞれ 7.2、6.0 dB である。この実験の範囲は、二つの HDR シーン、単一シード、16k 回の反復に限られる。実撮影シーンと SSS-GS シーンでは、他の点も異なる LiSA の旧来の表示領域版が 0.2–0.4 dB 高い結果を得る（補足資料）。[未実施] E4：アブレーション用シーン群で三つのシードを用い、(a) 全期間で表示領域の損失、(b) ウォームアップなし、(c) 段階 II で画素受光点、(d) 段階 III なし、(e) Γ 内へのオフセットを検証する。

受光点と微調整。Lego、Drums、Soap の 30k 時点の幾何形状を固定した実験（補足資料の表 S6）では、線形放射輝度ではなく表示領域で微調整すると、両種の受光点で三指標すべてが改善する（PSNR はガウシアンで +0.20 dB、画素で +0.28 dB）。画素受光点は最良の SSIM と LPIPS（0.976、0.029）を得る一方、ガウシアン受光点の PSNR は 0.19 dB 高い。本研究では知覚品質を重視して画素を採用する。

5.5. 計算コスト

Drums、FurScene、Soap において他の処理がない GPU で計測すると（補足資料の表 S5）、LiSA は GS³ と SSD-GS より 1.6–5.5 倍速く学習する。

Drums のガウシアン数は LiSA が 228k であるのに対し、両ベースラインは約 550k である。全 18 シーンでは計測条件がそれほど統一されていないが、平均学習時間は本手法が 21 分、ベースラインが 55–107 分である。毎フレームで新しい光源を用いても、光源パスを含むレンダリング速度は毎秒 63–104 フレームであり、対話的な操作が可能である。ただし、光源パスのため、小さいシーンでは GS³ と SSD-GS より遅い。

5.6. 限界

等方的ローブはヘアライン加工された金属や細い光の筋を捉えられない。Drums では、正解画像で細いハイライトとして抽出した 0.27% の画素が、GS³ に対する本手法の超過二乗誤差の 72% を占める。モーメント判定は複数の表面が混在する集約範囲に対して弱い事前知識にとどまり、中心深度を用いると大きな斜めのガウシアンの深度位置がずれる。チェビシェフ判定や四モーメント判定 [16, 42]、交差点の深度の利用は自然な改善案である。一枚の透視投影アトラスは光源が物体の外部にあることを仮定する。光輸送項は立体角係数と入射点での距離減衰を無視し、光源から見えない領域だけを經由して受光点に到達する光は、一回のライト空間での集約では扱えない。

6. 結論

点光源からガウシアンをラスタライズすると、各プリミティブが遮り受け取る光束の割合が記録される。LiSA は、この沈着を学習可能なアトラスへ変換し、光源ごとに一回の追加ラスタライズで、各受光点にフィルタ付きで補正可能なシャドウ判定と光輸送項を提供する。放射量に基づく段階的最適化と組み合わせることで、通常より大幅に短い学習時間で、三つのベンチマークを通じて最も一貫した性能を得る。光源に対する相対量を用いる設計が未観測の光源方向で有効かどうかは、今後実施する実験で検証する。

参考文献

- [1] Thomas Annen, Tom Mertens, Philippe Bekaert, Hans-Peter Seidel, and Jan Kautz. Convolution shadow maps. In *Eurographics Symposium on Rendering (EGSR)*, 2007. 3
- [2] Thomas Annen, Tom Mertens, Hans-Peter Seidel, Eddy Flerackers, and Jan Kautz. Exponential shadow maps. In *Proceedings of Graphics Interface*, 2008. 3
- [3] Sai Bi, Zexiang Xu, Pratul Srinivasan, Ben Mildenhall, Kalyan Sunkavalli, Milos Hasań, Yannick Hold-Geoffroy, David Kriegman, and Ravi Ramamoorthi. Neural reflectance fields for appearance acquisition. *arXiv preprint arXiv:2008.03824*, 2020. 1, 2
- [4] Sai Bi, Zexiang Xu, Kalyan Sunkavalli, Milos Hasań, Yannick Hold-Geoffroy, David Kriegman, and Ravi Ramamoorthi. Deep reflectance volumes: Relightable reconstructions from multi-view photometric images. In *European Conference on Computer Vision (ECCV)*, 2020. 2
- [5] Zoubin Bi, Yixin Zeng, Chong Zeng, Fan Pei, Xiang Feng, Kun Zhou, and Hongzhi Wu. GS³: Efficient relighting with triple Gaussian splatting. In *SIGGRAPH Asia Conference Papers*, 2024. 1, 2, 3, 6, 7
- [6] Luis Bolanos, Shih-Yang Su, and Helge Rhodin. Gaussian shadow casting for neural characters. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024. 3
- [7] Hongze Chen, Zehong Lin, and Jun Zhang. GI-GS: Global illumination decomposition on Gaussian splatting for inverse rendering. In *International Conference on Learning Representations (ICLR)*, 2025. 2
- [8] Cyril Crassin, Fabrice Neyret, Miguel Sainz, Simon Green, and Elmar Eisemann. Interactive indirect illumination using voxel cone tracing. *Computer Graphics Forum*, 30(7), 2011. 3
- [9] Carsten Dachsbacher and Marc Stamminger. Translucent shadow maps. In *Eurographics Symposium on Rendering (EGSR)*, 2003. 2, 3, 5
- [10] Carsten Dachsbacher and Marc Stamminger. Reflective shadow maps. In *Proceedings of the Symposium on Interactive 3D Graphics and Games (I3D)*, 2005. 2, 3
- [11] Carsten Dachsbacher and Marc Stamminger. Splatting indirect illumination. In *Proceedings of the Symposium on Interactive 3D Graphics and Games (I3D)*, 2006. 3
- [12] Sayantan Datta, Derek Nowrouzezahrai, Christoph Schied, and Zhao Dong. Neural shadow mapping. In *ACM SIGGRAPH Conference Proceedings*, 2022. 3
- [13] Paul Debevec, Tim Hawkins, Chris Tchou, Haarm-Pieter Duiker, Westley Sarokin, and Mark Sagar. Acquiring the reflectance field of a human face. In *Proceedings of SIGGRAPH*, pages 145–156, 2000. 1
- [14] Eugene d'Eon, David Luebke, and Eric Enderton. Efficient rendering of human skin. In *Eurographics Symposium on Rendering (EGSR)*, 2007. 3, 5
- [15] Jan-Niklas Dihlmann, Arjun Majumdar, Andreas Engelhardt, Raphael Braun, and Hendrik P. A. Lensch. Subsurface scattering for Gaussian splatting. In *Advances in Neural Information Process-*

- ing Systems (*NeurIPS*), pages 121765–121789, 2024. 2, 3, 6
- [16] William Donnelly and Andrew Lauritzen. Variance shadow maps. In *Proceedings of the Symposium on Interactive 3D Graphics and Games (I3D)*, 2006. 2, 3, 4, 10
- [17] Jiahui Fan, Fujun Luan, Jian Yang, Milos Hasaň, and Beibei Wang. RNG: Relightable neural Gaussians. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025. 1, 2, 3, 5, 6, 7
- [18] Randima Fernando. Percentage-closer soft shadows. In *ACM SIGGRAPH Sketches*, 2005. 3
- [19] Duan Gao, Guojun Chen, Yue Dong, Pieter Peers, Kun Xu, and Xin Tong. Deferred neural lighting: Free-viewpoint relighting from unstructured photographs. *ACM Transactions on Graphics*, 39(6), 2020. 3
- [20] Jian Gao, Chun Gu, Youtian Lin, Zhihao Li, Hao Zhu, Xun Cao, Li Zhang, and Yao Yao. Relightable 3D Gaussians: Realistic point cloud relighting with BRDF decomposition and ray tracing. In *European Conference on Computer Vision (ECCV)*, 2024. 2, 3
- [21] Chun Gu, Xiaofei Wei, Zixuan Zeng, Yuxuan Yao, and Li Zhang. IRGS: Inter-reflective Gaussian splatting with 2D Gaussian ray tracing. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025. 2, 3
- [22] Yijia Guo, Yuanxi Bai, Liwen Hu, Ziyi Guo, Mianzhi Liu, Yu Cai, Tiejun Huang, and Lei Ma. PRTGS: Precomputed radiance transfer of Gaussian splats for real-time high-quality relighting. In *Proceedings of the ACM International Conference on Multimedia (MM)*, 2024. 3
- [23] Letian Huang, Jiayang Bai, Jie Guo, Yuanqi Li, and Yanwen Guo. On the error analysis of 3D Gaussian splatting and an optimal projection strategy. In *European Conference on Computer Vision (ECCV)*, 2024. 3
- [24] Jon Jansen and Louis Bavoil. Fourier opacity mapping. In *Proceedings of the ACM SIGGRAPH Symposium on Interactive 3D Graphics and Games (I3D)*, pages 165–172, 2010. 3
- [25] Henrik Wann Jensen, Stephen R. Marschner, Marc Levoy, and Pat Hanrahan. A practical model for subsurface light transport. In *Proceedings of SIGGRAPH*, 2001. 3
- [26] Kaiwen Jiang, Jia-Mu Sun, Zilu Li, Dan Wang, Tzu-Mao Li, and Ravi Ramamoorthi. Differentiable light transport with Gaussian surfels via adapted radiosity for efficient relighting and geometry reconstruction. *ACM Transactions on Graphics (Proc. SIGGRAPH Asia)*, 2025. 3
- [27] Yingwenqi Jiang, Jiadong Tu, Yuan Liu, Xifeng Gao, Xiaoxiao Long, Wenping Wang, and Yuexin Ma. GaussianShader: 3D Gaussian splatting with shading functions for reflective surfaces. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024. 2
- [28] Jorge Jimenez, David Whelan, Veronica Sundstedt, and Diego Gutierrez. Real-time realistic skin translucency. *IEEE Computer Graphics and Applications*, 30(4), 2010. 3, 5
- [29] Haian Jin, Isabella Liu, Peijia Xu, Xiaoshuai Zhang, Songfang Han, Sai Bi, Xiaowei Zhou, Zexiang Xu, and Hao Su. TensorIR: Tensorial inverse rendering. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023. 2
- [30] Anton Kaplanyan and Carsten Dachsbacher. Cascaded light propagation volumes for real-time indirect illumination. In *Proceedings of the Symposium on Interactive 3D Graphics and Games (I3D)*, 2010. 3
- [31] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, and George Drettakis. 3D gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 42(4), 2023. 1, 3, 6
- [32] Tae-Yong Kim and Ulrich Neumann. Opacity shadow maps. In *Eurographics Workshop on Rendering Techniques*, 2001. 3
- [33] Zhiyi Kuang, Yanchao Yang, Siyan Dong, Jiayue Ma, Hongbo Fu, and Youyi Zheng. OLAT Gaussians for generic relightable appearance acquisition. In *SIGGRAPH Asia Conference Papers*, pages 1–11, 2024. 1, 2, 3, 6, 7
- [34] Zhihao Liang, Qi Zhang, Ying Feng, Ying Shan, and Kui Jia. GS-IR: 3D Gaussian splatting for inverse rendering. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024. 2
- [35] Zhenyuan Liu, Yu Guo, Xinyuan Li, Bernd Bickel, and Ran Zhang. BiGS: Bidirectional Gaussian primitives for relightable 3D Gaussian splatting. In *International Conference on 3D Vision (3DV)*, 2025. 1, 3
- [36] Tom Lokovic and Eric Veach. Deep shadow maps. In *Proceedings of SIGGRAPH*, 2000. 3
- [37] Linjie Lyu, Ayush Tewari, Thomas Leimkühler, Marc Habermann, and Christian Theobalt. Neural radiance transfer fields for relightable novel-view synthesis with global illumination. In *European Conference on Computer Vision (ECCV)*, 2022. 3
- [38] Ben Mildenhall, Peter Hedman, Ricardo Martin-Brualla, Pratul P. Srinivasan, and Jonathan T. Barron. NeRF in the dark: High dynamic range view synthesis from noisy raw images. In *Proceedings*

- of the *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022. 3, 5
- [39] Aymen Mir, Riza Alp Guler, Jian Wang, Gerard Pons-Moll, and Bing Zhou. Animated 3DGS avatars in diverse scenes with consistent lighting and shadows. *arXiv preprint arXiv:2601.01660*, 2026. 3
- [40] Nicolas Moenne-Loccoz, Ashkan Mirzaei, Or Perel, Riccardo de Lutio, Janick Martinez Esturo, Gavriel State, Sanja Fidler, Nicholas Sharp, and Zan Gojcic. 3D Gaussian ray tracing: Fast tracing of particle scenes. *ACM Transactions on Graphics*, 43(6), 2024. 3
- [41] Oliver Nalbach, Elena Arabadzhiyska, Dushyant Mehta, Hans-Peter Seidel, and Tobias Ritschel. Deep shading: Convolutional neural networks for screen space shading. *Computer Graphics Forum*, 36(4), 2017. 3
- [42] Christoph Peters and Reinhard Klein. Moment shadow mapping. In *Proceedings of the ACM SIGGRAPH Symposium on Interactive 3D Graphics and Games (I3D)*, 2015. 2, 3, 4, 10
- [43] Christoph Peters, Cedrick Münstermann, Nico Wetzstein, and Reinhard Klein. Beyond hard shadows: Moment shadow maps for single scattering, soft shadows and translucent occluders. In *Proceedings of the ACM SIGGRAPH Symposium on Interactive 3D Graphics and Games (I3D)*, 2016. 3
- [44] Lukas Radl, Michael Steiner, Mathias Parger, Alexander Weinrauch, Bernhard Kerbl, and Markus Steinberger. StopThePop: Sorted Gaussian splatting for view-consistent real-time rendering. *ACM Transactions on Graphics*, 43(4), 2024. 3
- [45] William T. Reeves, David H. Salesin, and Robert L. Cook. Rendering antialiased shadows with depth maps. In *Proceedings of SIGGRAPH*, pages 283–291, 1987. 3
- [46] Shunsuke Saito, Gabriel Schwartz, Tomas Simon, Junxuan Li, and Giljoo Nam. Relightable Gaussian codec avatars. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024. 3
- [47] Marco Salvi, Kiril Vidimcǎ, Andrew Lauritzen, and Aaron Lefohn. Adaptive volumetric shadow maps. *Computer Graphics Forum*, 29(4):1289–1296, 2010. 3
- [48] Mohammad Shafiei, Sai Bi, Zhengqin Li, Aidan Liaudanskas, Rodrigo Ortiz-Cayon, and Ravi Ramamoorthi. Learning neural transmittance for efficient rendering of reflectance fields. In *British Machine Vision Conference (BMVC)*, 2021. 3
- [49] Peter-Pike Sloan, Jan Kautz, and John Snyder. Pre-computed radiance transfer for real-time rendering in dynamic, low-frequency lighting environments. *ACM Transactions on Graphics*, 21(3), 2002. 3
- [50] Pratul P. Srinivasan, Boyang Deng, Xiuming Zhang, Matthew Tancik, Ben Mildenhall, and Jonathan T. Barron. NeRV: Neural reflectance and visibility fields for relighting and view synthesis. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021. 2
- [51] Chinmay Talegaonkar, Yash Belhe, Ravi Ramamoorthi, and Nicholas Antipa. Volumetrically consistent 3D Gaussian rasterization. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025. 3
- [52] Justus Thies, Michael Zollhöfer, and Matthias Nießner. Deferred neural rendering: Image synthesis using neural textures. *ACM Transactions on Graphics*, 38(4), 2019. 3
- [53] Peng Wang, Lingjie Liu, Yuan Liu, Christian Theobalt, Taku Komura, and Wenping Wang. NeuS: Learning neural implicit surfaces by volume rendering for multi-view reconstruction. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. 3
- [54] Shaofei Wang, Tomas Simon, Igor Santesteban, Timur Bagautdinov, Junxuan Li, Vasu Agrawal, Fabian Prada, Shou-I Yu, Pace Nalbone, Matt Gramlich, Roman Lubachersky, Chenglei Wu, Javier Romero, Jason Saragih, Michael Zollhoefer, Andreas Geiger, Siyu Tang, and Shunsuke Saito. Relightable full-body Gaussian codec avatars. In *ACM SIGGRAPH Conference Papers*, 2025. 3
- [55] Zhou Wang, Alan C. Bovik, Hamid R. Sheikh, and Eero P. Simoncelli. Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4):600–612, 2004. 6
- [56] Lance Williams. Casting curved shadows on curved surfaces. In *Proceedings of SIGGRAPH*, pages 270–274, 1978. 2, 3
- [57] Peiyu Xu, Xin Sun, Krishna Mullia, Raymond Fei, Iliyan Georgiev, and Shuang Zhao. Stochastic ray tracing for the reconstruction of 3D Gaussian splatting. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2026. 3
- [58] Keyang Ye, Qiming Hou, and Kun Zhou. 3D Gaussian splatting with deferred reflection. In *ACM SIGGRAPH Conference Papers*, 2024. 3
- [59] Vickie Ye, Ruilong Li, Justin Kerr, Matias Turkulainen, Brent Yi, Zhuoyang Pan, Otto Seiskari, Jianbo Ye, Jeffrey Hu, Matthew Tancik, and Angjoo Kanazawa. gsplat: An open-source library for Gaussian splatting. *Journal of Machine Learning Research*, 26(34):1–17, 2025. 6

- 922 [60] Zehao Yu, Anpei Chen, Binbin Huang, Torsten Sattler, and Andreas Geiger. Mip-splatting: Alias-free 3D Gaussian splatting. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024. 3
- 923
- 924
- 925
- 926
- 927 [61] Cem Yuksel and John Keyser. Deep opacity maps. *Computer Graphics Forum*, 27(2), 2008. 3
- 928
- 929 [62] Chong Zeng, Guojun Chen, Yue Dong, Pieter Peers, Hongzhi Wu, and Xin Tong. Relighting neural radiance fields with shadow and highlight hints. In *ACM SIGGRAPH Conference Proceedings*, 2023. 1, 2, 5, 6
- 930
- 931
- 932
- 933
- 934 [63] Richard Zhang, Phillip Isola, Alexei A. Efros, Eli Shechtman, and Oliver Wang. The unreasonable effectiveness of deep features as a perceptual metric. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018. 6
- 935
- 936
- 937
- 938
- 939
- 940 [64] Xiuming Zhang, Sean Fanello, Yun-Ta Tsai, Tiancheng Sun, Tianfan Xue, Rohit Pandey, Sergio Orts-Escolano, Philip Davidson, Christoph Rhemann, Paul Debevec, Jonathan T. Barron, Ravi Ramamoorthi, and William T. Freeman. Neural light transport for relighting and view synthesis. *ACM Transactions on Graphics*, 40(1), 2021. 3
- 941
- 942
- 943
- 944
- 945
- 946
- 947
- 948 [65] Xiuming Zhang, Pratul P. Srinivasan, Boyang Deng, Paul Debevec, William T. Freeman, and Jonathan T. Barron. NeRFactor: Neural factorization of shape and reflectance under an unknown illumination. *ACM Transactions on Graphics*, 40(6), 2021. 2
- 949
- 950
- 951
- 952
- 953
- 954 [66] Iris Zheng, Guojun Tang, Alexander Doronin, Paul Teal, and Fang-Lue Zhang. SSD-GS: Scattering and shadow decomposition for relightable 3D Gaussian splatting. In *International Conference on Learning Representations (ICLR)*, 2026. 1, 2, 3, 6, 7
- 955
- 956
- 957
- 958
- 959